







第6章 支持向量机(SVM)

Support Vector Machine

一、支持向量机解决什么问题？

- ✎ 要解决的问题：什么样的决策边界才是最好的呢？
- ✎ 特征数据本身如果就很难分，怎么办呢？
- ✎ 计算复杂度怎么样？能实际应用吗？






一、线性可分支持向量机

1、线性可分问题


$$w^T x + b = 0$$

$$f(x) = \text{sgn}(w^{*T}x + b^*)$$



一、线性可分支支持向量机

2、最大间隔超平面



一、线性可分支持向量机

✓ 距离的计算

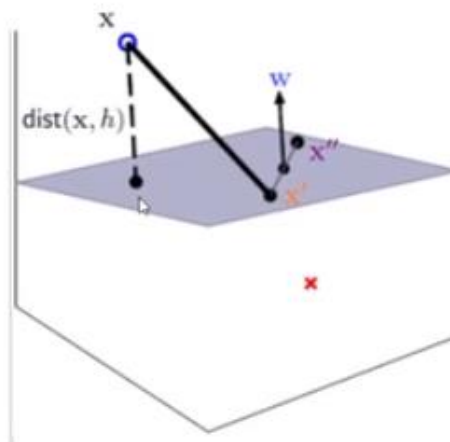
consider \mathbf{x}' , \mathbf{x}'' on hyperplane

① $\mathbf{w}^T \mathbf{x}' = -b$, $\mathbf{w}^T \mathbf{x}'' = -b$

② $\mathbf{w} \perp$ hyperplane:

$$\begin{pmatrix} \mathbf{w}^T \underbrace{(\mathbf{x}'' - \mathbf{x}')}_{\text{vector on hyperplane}} \end{pmatrix} = 0$$

③ distance = project $(\mathbf{x} - \mathbf{x}')$ to \perp hyperplane



$$\text{distance}(\mathbf{x}, \mathbf{b}, \mathbf{w}) = \left| \frac{\mathbf{w}^T}{\|\mathbf{w}\|} (\mathbf{x} - \mathbf{x}') \right| \stackrel{\textcircled{1}}{=} \frac{1}{\|\mathbf{w}\|} |\mathbf{w}^T \mathbf{x} + b|$$

$$d = \frac{|w^T x + b|}{\|w\|} = \frac{y_i (w^T x_i + b)}{\|w\|}$$



一、线性可分支持向量机

3、最优化问题

$$\arg \max_{w,b} \left\{ \frac{1}{\|w\|} \min_i \left[y_i \cdot (w^T x_i + b) \right] \right\}$$

$$y_i (W^T x_i + b) \geq 1$$

$$\arg \max_{w,b} \frac{1}{\|w\|}$$

最优化问题

$$\min \frac{1}{2} w^2$$

$$s.t \quad 1 - y_i (w^T x_i + b) \leq 0 \quad (i = 1, 2, \dots, N)$$



一、线性可分支持向量机

4、构造拉格朗日函数

$$L(w, b, \lambda) = \frac{1}{2} w^2 + \sum_{i=1}^N \lambda_i (1 - y_i (w^T x_i + b))$$

$$s.t \quad \lambda_i \geq 0$$

$$\min_{w, b} \max_{\lambda} L(w, b, \lambda) = \frac{1}{2} w^2 + \sum_{i=1}^N \lambda_i (1 - y_i (w^T x_i + b))$$

$$s.t \quad \lambda_i \geq 0$$

5、强对偶问题

$$\max_{\lambda} \min_{w, b} L(w, b, \lambda) = \min_{w, b} \max_{\lambda} L(w, b, \lambda)$$



一、线性可分支持向量机

6、对w、b求偏导

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^N \lambda_i y_i x_i = 0$$

$$\frac{\partial L}{\partial b} = \sum_{i=1}^N \lambda_i y_i = 0$$

$$\begin{cases} w = \sum_{i=1}^N \lambda_i y_i x_i \\ \sum_{i=1}^N \lambda_i y_i = 0 \end{cases}$$



一、线性可分支持向量机

7、最终优化问题

$$\begin{aligned}\min_{w,b} L(w,b,\lambda) &= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \lambda_i - \sum_{i=1}^N \lambda_i y_i \left(\sum_{i=1}^N \lambda_i y_i (x_i \cdot x_j) + b \right) \\ &= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \lambda_i - \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \lambda_i y_i b \\ &= \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j y_i y_j (x_i \cdot x_j)\end{aligned}$$



一、线性可分支持向量机

$$\left\{ \begin{array}{l} \max_{\lambda} \left[\sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) \right] \\ s.t. \quad \sum_{i=1}^N \lambda_i y_i = 0 \\ \lambda_i \geq 0 \end{array} \right.$$

$$\left\{ \begin{array}{l} \min_{\lambda} \left[\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \lambda_i \right] \\ s.t. \quad \sum_{i=1}^N \lambda_i y_i = 0 \\ \lambda_i \geq 0 \end{array} \right.$$



一、线性可分支持向量机

$$\lambda^* = (\lambda_1^*, \lambda_2^*, \dots, \lambda_N^*)$$

$$w^* = \sum_{i=1}^N \lambda_i^* y_i x_i \quad (\text{选择 } \lambda_i^* > 0)$$

$$b^* = y_j - \sum_{i=1}^N \lambda_i^* y_i (x_i \cdot x_j)$$

8、获得超平面

$$w^{*T} x + b^* = 0$$


9、分类决策

$$f(x) = \text{sgn}(w^{*T} x + b^*)$$



一、线性可分支持向量机

例：已知一个如图所示的训练数据集，其正例点是 $x_1=(3,3)^T$ ， $x_2=(4,3)^T$ ，负例点是 $x_3=(1,1)^T$ ，试求最大间隔分离超平面。





一、线性可分支持向量机

$$x_1 = (3, 3)^T \rightarrow y_1 = 1$$

$$x_2 = (4, 3)^T \rightarrow y_2 = 1$$

$$x_3 = (1, 1)^T \rightarrow y_3 = -1$$

$$\min_{\alpha} \begin{cases} \frac{1}{2} \sum_{i=1}^3 \sum_{j=1}^3 \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^3 \alpha_i \\ \sum_{i=1}^3 \alpha_i y_i = 0 \\ \alpha_i \geq 0 \end{cases}$$

$$\begin{cases} \frac{1}{2} (18\alpha_1^2 + 25\alpha_2^2 + 2\alpha_3^2 + 42\alpha_1\alpha_2 - 12\alpha_1\alpha_3 - 14\alpha_2\alpha_3) - \alpha_1 - \alpha_2 - \alpha_3 \\ \alpha_1 + \alpha_2 - \alpha_3 = 0 \\ \alpha_i \geq 0 \quad i = 1, 2, 3 \end{cases}$$



一、线性可分支持向量机

$$\alpha_3 = \alpha_1 + \alpha_2$$

$$L = 4\alpha_1^2 + \frac{13}{2}\alpha_2^2 + 10\alpha_1\alpha_2 - 2\alpha_1 - 2\alpha_2$$

$$\frac{\partial L}{\partial \alpha_1} = 0, \quad \frac{\partial L}{\partial \alpha_2} = 0 \quad \text{得}$$

$$\alpha_1 = 1.5 \quad \alpha_2 = -1 \quad \text{不满足 } \alpha_i \geq 0, i = 1, 2, 3$$

最终的解应该为边界上的点

$$\alpha_1 = 0, \quad \alpha_2 = -\frac{2}{13}$$

$$\alpha_2 = 0, \quad \alpha_1 = 0.25$$

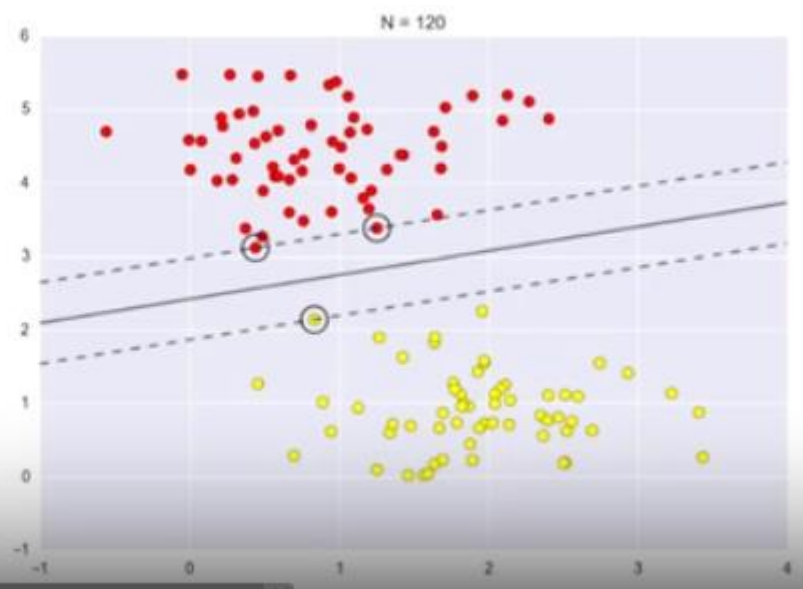

$$\alpha_3 = \alpha_1 + \alpha_2 = 0.25$$

最小值在 $(0.25, 0, 0.25)$ $w_1 = w_2 = 0.5$ $b = -2$

$$0.5x_1 + 0.5x_2 - 2 = 0$$

一、线性可分支持向量机

 支持向量：真正发挥作用的数据点， α 值不为0的点




二、软间隔支持向量机

✎ 软间隔：有时候数据中有一些噪音点，如果考虑它们咱们的线就不太好了

✎ 之前的方法要求要把两类点完全分得开，这个要求有点过于严格了，我们来放松一点！

✎ 为了解决该问题，引入松弛因子

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i$$





二、软间隔支持向量机

引入松弛变量 $\xi_i \geq 0$ ，惩罚参数 C

$$\min_{W, b, \xi} \frac{1}{2} \|W\|^2 + C \sum_{i=1}^N \xi_i$$

$$\begin{aligned} s.t. \quad & y_i(W^T x_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0 \end{aligned} \quad i = 1, 2, \dots, N$$

拉格朗日函数

$$\left\{ \begin{aligned} L(w, b, \xi, \alpha, \mu) &= \frac{1}{2} w^2 + C \sum_{i=1}^N \xi_i + \sum_{i=1}^N \alpha_i (1 - \xi_i - y_i (w^T x_i + b)) - \sum_{i=1}^N \mu_i \xi_i \\ \alpha_i &\geq 0 \\ \mu_i &\geq 0 \end{aligned} \right.$$



二、软间隔支持向量机

原问题

$$\min_{w,b,\xi} \max_{\alpha,\mu} L(w,b,\xi,\alpha,\mu)$$

对偶问题

$$\max_{\alpha,\mu} \min_{w,b,\xi} L(w,b,\xi,\alpha,\mu)$$

$$\min_{w,b,\xi} L(w,b,\xi,\alpha,\mu) = \min_{w,b,\xi} \left[\frac{1}{2} w^2 + C \sum_{i=1}^N \xi_i + \sum_{i=1}^N \alpha_i [1 - \xi_i - y_i (w^T x_i + b)] - \sum_{i=1}^N \mu_i \xi_i \right]$$

$$\frac{\partial L(w,b,\xi,\alpha,\mu)}{\partial w} = w - \sum_{i=1}^N \alpha_i y_i x_i = 0$$

$$\frac{\partial L(w,b,\xi,\alpha,\mu)}{\partial b} = - \sum_{i=1}^N \alpha_i y_i = 0$$

$$\frac{\partial L(w,b,\xi,\alpha,\mu)}{\partial \xi_i} = C - \alpha_i - \mu_i = 0$$






二、软间隔支持向量机

$$\left\{ \begin{array}{l} w = \sum_{i=1}^N \alpha_i y_i x_i \\ \sum_{i=1}^N \alpha_i y_i = 0 \\ C - \alpha_i - \mu_i = 0 \end{array} \right.$$


$$\left\{ \begin{array}{l} \min_{\alpha} L(w, b, \xi, \alpha, \mu) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ s.t. \sum_{i=1}^N \alpha_i y_i = 0 \\ 0 \leq \alpha_i \leq C \end{array} \right.$$

三、非线性支持向量机





三、非线性支持向量机



$$(x_1, x_2, x_1^2 + x_2^2)$$

$$(x_i \cdot x_j) = \Phi(x_i)^T \Phi(x_j)$$



三、非线性支持向量机

$$x = (x_1, x_2, x_3)$$

$$z = (z_1, z_2, z_3)$$

$$f(x) = (x_1x_1, x_1x_2, x_1x_3, x_2x_1, x_2x_2, x_2x_3, x_3x_1, x_3x_2, x_3x_3)$$

$$x = (1, 2, 3) \quad z = (4, 5, 6)$$

$$f(x) = (1, 2, 3, 2, 4, 6, 3, 6, 9)$$

$$f(z) = (16, 20, 24, 20, 25, 36, 24, 30, 36)$$

$$f(x)^T f(y) = 16 + 40 + 72 + 40 + 100 + 180 + 72 + 180 + 324 = 1024$$

$$(x^T z)^2 = (4 + 10 + 18)^2 = 1024$$

$$K(x, z) = f^T(x) \cdot f(z)$$



三、非线性支持向量机

常用核函数

线性核函数:

$$K(x_i, x_j) = x_i^T x_j$$


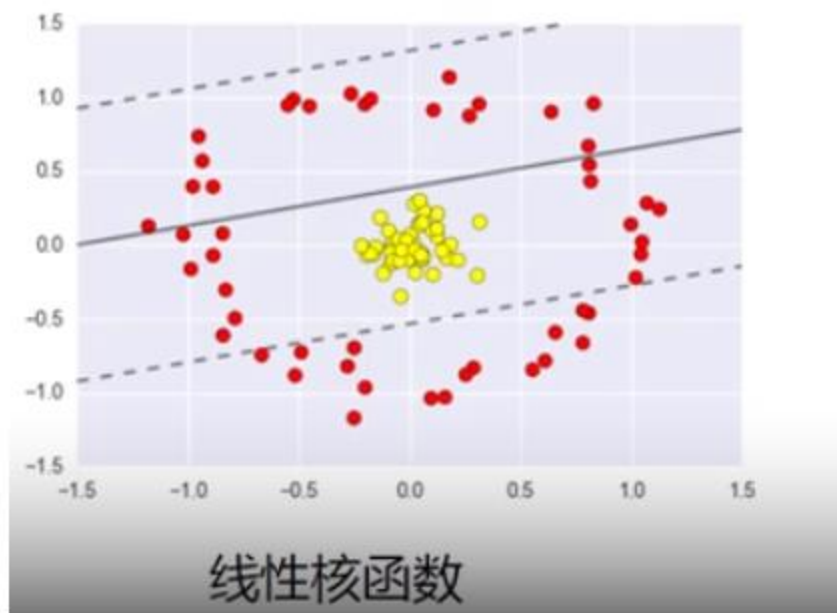
多项式核函数:

$$K(x_i, x_j) = (x_i^T x_j)^d$$

高斯核函数:

$$K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$$

三、非线性支持向量机





四、SMO算法 (Sequential Minimal Optimazation)

1、问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^N \alpha_i \\ \text{s. t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & i = 1, 2, \dots, N \\ & 0 \leq \alpha_i \leq C \end{aligned}$$


优化变量是拉格朗日乘子 α_i ，一个对应一个样本。



四、SMO算法 (Sequential Minimal Optimazation)

2、传统解决方法

(1) 梯度下降法



收敛快，计算复杂

(2) 坐标下降法

收敛慢，计算简单，（常用方法，但优化 α_i 不能用）



四、SMO算法 (Sequential Minimal Optimazation)

3、整体问题化为一系列子问题

每次最少调整两个变量，如果只调整一个，将会破坏 $\sum_{i=1}^N \alpha_i y_i = 0$ 约束条件，只有同时调整两个 α ，才能保证约束条件，这也是SMO的由来。这是一种很巧妙的思想。其它不调整的 α 不做任何变化，视为常数，本思路是由John Platt 提出的，这是一种具有影响力的算法，具有与FFT同等地位。

选择两个变量，其它变量固定，SMO将整体优化问题转化成一系列子问题：



四、SMO算法 (Sequential Minimal Optimazation)

$$\min_{\alpha_1, \alpha_2} W(\alpha_1, \alpha_2) = \frac{1}{2} K_{11} \alpha_1^2 + \frac{1}{2} K_{22} \alpha_2^2 + y_1 y_2 K_{12} \alpha_1 \alpha_2 + y_1 \alpha_1 \sum_{i=3}^N y_i \alpha_i K_{i1} +$$

$$y_2 \alpha_2 \sum_{i=3}^N y_i \alpha_i K_{i2} - (\alpha_1 + \alpha_2)$$

$$s.t. \quad \alpha_1 y_1 + \alpha_2 y_2 = - \sum_{i=3}^N y_i \alpha_i = \gamma$$

$$0 \leq \alpha_i \leq C, i = 1, 2$$

$$\begin{cases} \alpha_1 y_1 = -\alpha_2 y_2 + \zeta \\ \alpha_1 = -\alpha_2 y_1 y_2 + y_1 \zeta \end{cases}$$




四、SMO算法 (Sequential Minimal Optimazation)

问题变成了一元函数问题，可以得到解析解，基于初始可行解 $\alpha_1^{old}, \alpha_2^{old}$ ，可以得到 $\alpha_1^{new}, \alpha_2^{new}$ ，不用搜索，不用迭代，用解析公式直接求，这就是收敛速度快的原因。

无约束可求得一个解，如果是有约束问题呢？

4、约束与剪辑问题的处理




$$x \in [b, c] \quad x = c \text{ 最小}$$

$$x \in [e, f] \quad x = e \text{ 最小}$$

$$x \in [b, f] \text{ 与无约束优化一致}$$




四、SMO算法 (Sequential Minimal Optimazation)



$$y_1 \neq y_2 \Rightarrow \alpha_1 - \alpha_2 = K$$

$$\begin{cases} \alpha_1 y_1 + \alpha_2 y_2 = \zeta \\ \alpha_1 + (-\alpha_2) = y_1 \zeta = K \end{cases}$$



$$y_1 = y_2 \Rightarrow \alpha_1 + \alpha_2 = K$$

$$y_1 = y_2 \quad \alpha_1 + \alpha_2 = K$$



四、SMO算法 (Sequential Minimal Optimazation)

根据不等式条件 α_2^{new} 的取值范围 (两种情况, $y_1 \neq y_2, y_1 = y_2$)

第一种情况 $\alpha_2 = \alpha_1 - K \quad \alpha_1 \in [0, c]$

$$\alpha_1 - K \in [0 - K, c - K]$$

$$K = \alpha_1 - \alpha_2$$

$$\therefore \alpha_2 \in [\alpha_2 - \alpha_1, c + \alpha_2 - \alpha_1]$$

$$\text{同时} \quad \alpha_2 \in [0, c]$$

$$\textcircled{1} \begin{cases} L \leq \alpha_2^{new} \leq H \\ L = \max(0, \alpha_2^{old} - \alpha_1^{old}) \\ H = \min(c, c + \alpha_2^{old} - \alpha_1^{old}) \end{cases}$$



四、SMO算法 (Sequential Minimal Optimazation)

第二种情况 $\alpha_1 \in [0, c]$

$$K - \alpha_1 \in [K, K - c]$$

$$\alpha_2 \in [K, K - c]$$

同理
$$\begin{cases} \alpha_2 \in [\alpha_1 + \alpha_2, \alpha_1 + \alpha_2 - c] \\ \alpha_2 \in [0, c] \end{cases}$$

$$\textcircled{2} \quad \begin{cases} L = \max(0, \alpha_2^{old} + \alpha_1^{old}) \\ H = \min(c, \alpha_1^{old} + \alpha_2^{old} - c) \end{cases} \quad \begin{cases} \alpha_1^{new, un} \\ \alpha_2^{new, un} \end{cases} \quad \text{未剪辑}$$



四、SMO算法 (Sequential Minimal Optimazation)


5、求解过程

先求沿着约束方向未经剪辑时 $\alpha_2^{new,un}$ 再求剪辑后的 α_2^{new}

记: $g(x) = \sum_{i=1}^N \alpha_i y_i K(x_i, x) + b$

$$\text{令 } E_i = g(x_i) - y_i = \left(\sum_{j=1}^N \alpha_j y_j K(x_i, x_j) + b \right) - y_i, \quad i = 1, 2$$

E 为输入 x 的预测值和真实输出 y 的差, $i = 1, 2$



$$v_i = \sum_{j=3}^N \alpha_j y_j K(x_i, x_j) = g(x_i) - \sum_{j=1}^2 \alpha_j y_j K(x_i, x_j) - b \quad i = 1, 2$$



四、SMO算法 (Sequential Minimal Optimazation)

目标函数写成

$$W(\alpha_1, \alpha_2) = \frac{1}{2}K_{11}\alpha_1^2 + \frac{1}{2}K_{22}\alpha_2^2 + y_1y_2K_{12}\alpha_1\alpha_2 - (\alpha_1 + \alpha_2) + y_1v_1\alpha_1 + y_2v_2\alpha_2$$

$$\text{由 } \alpha_1 y_1 = \zeta - \alpha_2 y_2 \quad \text{设 } y_i^2 = 1$$

$$\alpha_1 = (\zeta - y_2 \alpha_2) y_1$$

得到只有 α_2 的目标函数

$$\begin{aligned} W(\alpha_2) = & \frac{1}{2}K_{11}(\zeta - \alpha_2 y_2)^2 + \frac{1}{2}K_{22}\alpha_2^2 + y_2K_{12}(\zeta - \alpha_2 y_2)\alpha_2 \\ & - (\zeta - \alpha_2 y_2)y_1 - \alpha_2 + v_1(\zeta - \alpha_2 y_2) + y_2v_2\alpha_2 \end{aligned}$$



四、SMO算法 (Sequential Minimal Optimazation)

对 α_2 求导

$$\frac{\partial W}{\partial \alpha_2} = K_{11}\alpha_2 + K_{22}\alpha_2 - 2K_{12}\alpha_2 - K_{11}\zeta y_2 + K_{12}\zeta y_2 + y_1 y_2 - 1 - v_1 y_2 + y_2 v_2 = 0$$

$$(K_{11} + K_{22} - 2K_{12})\alpha_2 = y_2 (y_2 - y_1 + \zeta K_{11} - \zeta K_{12} + v_1 - v_2)$$

$$= y_2 \left(y_2 - y_1 + \zeta K_{11} - \zeta K_{12} + \left(g(x_1) - \sum_{j=1}^2 y_j \alpha_j K_{1j} - b \right) - \left(g(x_2) - \sum_{j=1}^2 y_j \alpha_j K_{2j} - b \right) \right)$$

式子虽长，但只有一个变量，最高二次方

将 $\zeta = \alpha_1^{old} y_1 + \alpha_2^{old} y_2$ 代入

$$\begin{aligned} (K_{11} + K_{22} - 2K_{12})\alpha_2^{new,un} &= y_2 \left((K_{11} + K_{22} - 2K_{12})\alpha_2^{old} y_2 + y_2 - y_1 + g(x_1) - g(x_2) \right) \\ &= (K_{11} + K_{22} - 2K_{12})\alpha_2^{old} + y_2 (E_1 - E_2) \end{aligned}$$



四、SMO算法 (Sequential Minimal Optimazation)

$$\text{令 } \eta = K_{11} + K_{22} - 2K_{12}$$

$$\alpha_2^{\text{new}, \text{un}} = \alpha_2^{\text{old}} + \frac{y_2 (E_1 - E_2)}{\eta}$$

$$\eta = K_{11} + K_{22} - 2K_{12} = \|\Phi(x_1) - \Phi(x_2)\|^2$$

剪辑后得

$$\alpha_2^{\text{new}} = \begin{cases} H & \alpha_2^{\text{new}, \text{un}} > H \\ \alpha_2^{\text{new}, \text{un}} & L \leq \alpha_2^{\text{new}, \text{un}} \leq H \\ L & \alpha_2^{\text{new}, \text{un}} < L \end{cases}$$



四、SMO算法 (Sequential Minimal Optimazation)

得到 α_1 的解

$$\alpha_1^{new} = \alpha_1^{old} + y_1 y_2 (\alpha_2^{old} - \alpha_2^{new})$$

为了下一轮迭代, 需要计算 b 和 E_i 完成两个变量的优化后,
重新计算 b 和 E_i 由KKT条件, 如果 $0 < \alpha_1^{new} < c$ (支持向量)

$$\sum_{i=1}^N \alpha_i y_i K_{i1} + b = y_1$$

$$b_1^{new} = y_1 - \sum_{i=3}^N \alpha_i y_i K_{i1} - \alpha_1^{new} y_1 K_{11} - \alpha_2^{new} y_2 K_{21}$$

$$E_i = g(x_i) - y_i = \left(\sum_{j=1}^N \alpha_j y_j K(x_j, x_i) + b \right) - y_i \quad i = 1, 2$$

$$E_1 = \sum_{i=3}^N \alpha_i y_i K_{i1} + \alpha_1^{old} y_1 K_{11} + \alpha_2^{old} y_2 K_{21} + b^{old} - y_1$$



四、SMO算法 (Sequential Minimal Optimazation)

$$y_1 - \sum_{i=3}^N \alpha_i y_i K_{i1} = -E_1 + \alpha_1^{old} y_1 K_{11} + \alpha_2^{old} y_2 K_{21} + b^{old}$$

$$b_1^{new} = -E_1 - y_1 K_{11} (\alpha_1^{new} - \alpha_1^{old}) - y_2 K_{21} (\alpha_2^{new} - \alpha_2^{old}) + b^{old}$$

b_1^{new} 只与 α_1 、 α_2 有关

如果 $0 < \alpha_2^{new} < c$

$$b_2^{new} = -E_2 - y_1 K_{12} (\alpha_1^{new} - \alpha_1^{old}) - y_2 K_{22} (\alpha_2^{new} - \alpha_2^{old}) + b^{old}$$

$$E_i^{new} = \sum_S y_j \alpha_j K(x_i, x_j) + b^{new} - y_i$$

S 是所有支持向量 x_j 的集合

如果 $\alpha_1^{new}, \alpha_2^{new}$ 同时满足条件 $0 < \alpha_i^{new} < c (i=1,2)$, 那么 $b_1^{new} = b_2^{new}$ 。如果 $\alpha_1^{new}, \alpha_2^{new}$ 是 0 或者 c , 那么 b_1^{new} 和 b_2^{new} 以及它们之间的数都是符合 KKT 条件的阈值, 这时选择它们的中点作为 b^{new} 。

以上是SMO的主要框架



四、SMO算法 (Sequential Minimal Optimazation)

6、变量的启发式选择

SMO算法在每个子问题中选择两个变量，其中至少一个变量是违反KKT条件的

1、第一个变量的选择（外循环）

- 违反KKT最严重的样本点
- 检验样本点是否满足KKT条件

$$\alpha_i = 0 \leftrightarrow y_i g(x_i) > 1$$

$$0 < \alpha_i < c \leftrightarrow y_i g(x_i) = 1$$

$$\alpha_i = c \leftrightarrow y_i g(x_i) < 1$$

$$g(x_i) = \sum_{j=1}^N \alpha_j y_j K(x_i, x_j) + b$$



四、SMO算法 (Sequential Minimal Optimazation)

2、第二个变量的检查（内循环）

选择的标准量希望能使目标函数有足够大的变化即对应 $|E_1 - E_2|$ 最大，即 E_1 ， E_2 符号相反，差异最大。如果内循环通过上述方法找到的点不能使目标函数有足够大的下降，则遍历间隔边界上的样本点，测试目标函数下降，如果下降不大，则遍历所有样本点，如果依然下降不大，则丢弃外循环点，重新选择。

SMO算法流程略。