




第4章 经典人工神经网络

反馈神经网络

1982年美国加州理工Hopfield教授提出的：DHNN、CHNN。



该网络不用训练，权值、阈值是设计出来的，只有 x 变化。



反馈神经网络

1、网络的状态

DHNN网中的每个神经元都有相同的功能，其输出称为状态，用 x_j 表示。

所有神经元状态的集合就构成反馈网络的状态

$$X=[x_1, x_2, \dots, x_n]^T \quad \text{输入输出合二为一，同一符号表示。}$$

反馈网络的输入就是网络的状态初始值，表示为

$$X(0)=[x_1(0), x_2(0), \dots, x_n(0)]^T \longrightarrow \text{激发作用}$$

反馈网络在外界输入激发下，从初始状态进入动态演变过程，变化规律为

$$x_j = f(\text{net}_j) \quad j = 1, 2, \dots, n$$



反馈神经网络

1、网络的状态

DHNN网的转移函数常采用符号函数

$$f = \text{sgn}(net_j) = \begin{cases} 1 & net_j \geq 0 \\ -1 & net_j < 0 \end{cases} \quad j=1,2,\dots,n$$

$$net_j = \sum_{i=1}^n (w_{ij} x_i) - T_j \quad j=1,2,\dots,n$$

对于DHNN网，一般有 $w_{ii}=0$ ， $w_{ij}=w_{ji}$ 。（ n 阶方阵，主对角线为0，无自反馈）

反馈网络稳定时每个神经元的状态都不再改变，此时的稳定状态就是网络的输出，表示为

$$\lim_{t \rightarrow \infty} X(t)$$



反馈神经网络

2、网络的异步工作方式

网络运行时每次只有一个神经元 j 进行状态的调整计算，其它神经元的状态均保持不变，即

$$x_j(t+1) = \begin{cases} \text{sgn}[net_j(t)] & j = i \\ x_j(t) & j \neq i \end{cases}$$

3、网络的同步工作方式

网络的同步工作方式是一种并行方式，所有神经元同时调整状态，即

$$x_j(t+1) = \text{sgn}[net_j(t)] \quad j = 1, 2, \dots, n$$




反馈神经网络

4、网络的稳定性

DHNN网实质上是一个离散的非线性动力学系统。网络从初态 $\mathbf{X}(0)$ 开始，若能经有限次递归后，其状态不再发生变化，即 $\mathbf{X}(t+1)=\mathbf{X}(t)$ ，则称该网络是稳定的。


如果网络是稳定的，它可以从任一初态收敛到一个稳态：






反馈神经网络

若网络是不稳定的，由于DHNN网每个节点的状态只有1和-1两种情况，网络不可能出现无限发散的情况，而只可能出现限幅的**自持振荡**，这种网络称为**有限环网络**。



如果网络状态的轨迹在某个确定的范围内变迁，但既不重复也不停止，状态变化为无穷多个，轨迹也不发散到无穷远，这种现象称为**混沌**。



实际上DHNN不会出现混沌



反馈神经网络

5、网络吸引子

网络达到稳定时的状态 X ，称为网络的吸引子。

DHNN有何用？ 优化计算与联想记忆

如何把问题的解编码为网络的吸引子，从初态向吸引子演变的过程便是求解计算的过程。

若把需记忆的样本信息存储于网络不同的吸引子，当输入含有部分记忆信息的样本时，网络的演变过程便是从部分信息寻找全部信息，即联想回忆的过程。[例：多年不见老朋友]

定义： 若网络的状态 X 满足

$$X=f(WX-T)$$

则称 X 为网络的吸引子。



反馈神经网络

定理：对于DHNN 网，若按异步方式调整网络状态，且连接权矩阵 W 为对称阵，则对于任意初态，网络都最终收敛到一个吸引子。

证明：定义网络的能量函数为：

$$E(t) = -\frac{1}{2}X^T(t)WX(t) + X^T(t)T$$

令网络的能量改变量为 ΔE ，状态改变量为 ΔX ，有

$$\Delta E(t) = E(t+1) - E(t)$$

$$\Delta X(t) = X(t+1) - X(t)$$

定理：对于DHNN网，若按同步方式调整状态，且连接权矩阵 W 为非负定对称阵，则对于任意初态，网络都最终收敛到一个吸引子。



反馈神经网络

$$\begin{aligned}\Delta E(t) &= E(t+1) - E(t) \\&= -\frac{1}{2}[X(t) + \Delta X(t)]^T W [X(t) + \Delta X(t)] + [X(t) + \Delta X(t)]^T T \\&\quad - [-\frac{1}{2}X^T(t)WX(t) + X^T(t)T] \\&= -\Delta X^T(t)WX(t) - \frac{1}{2}\Delta X^T(t)W\Delta X(t) + \Delta X^T(t)T \\&= -\Delta X^T(t)[WX(t) - T] - \frac{1}{2}\Delta X^T(t)W\Delta X(t)\end{aligned}$$

将 $\Delta X(t) = [0, \dots, 0, \Delta x_j(t), 0, \dots, 0]^T$ 代入上式，并考虑到 W 为对称矩阵，有

$$\begin{aligned}\Delta E(t) &= -\Delta x_j(t) \left[\sum_{i=1}^n (w_{ij}x_i) - T_j \right] - \frac{1}{2}\Delta x_j^2(t)w_{jj} \\&= -\Delta x_j(t)net_j(t)\end{aligned}$$



反馈神经网络

上式中可能出现的情况：

情况①： $x_j(t)=-1$ ， $x_j(t+1)=1$ ， $\Delta x_j(t)=2$ ，

$$\text{net}_j(t) \geq 0, \quad \Delta E(t) \leq 0$$

情况②： $x_j(t)=1$ ， $x_j(t+1)=-1$ ， $\Delta x_j(t)=-2$ ，

$$\text{net}_j(t) < 0, \quad \Delta E(t) < 0$$

情况③： $x_j(t)=x_j(t+1)$ ， $\Delta x_j(t)=0$ ，

$$\Delta E(t)=0$$

由此可知在任何情况下均有 $\Delta E(t) \leq 0$ ，最终 $\Delta E(t)=0$ ，状态不再改变，最终收敛到一个吸引子。



反馈神经网络

6、吸引子性质

性质1：若 X 是网络的一个吸引子，且阈值 $T=0$ ，在 $\text{sgn}(0)$ 处， $x_j(t+1)=x_j(t)$ ，则 $-X$ 也一定是该网络的吸引子。

证明： $\because X$ 是吸引子，即 $X=f(WX)$ ，从而有

$$f[W(-X)]=f[-WX]=-f[WX]=-X$$

$\therefore -X$ 也是该网络的吸引子。



反馈神经网络

性质2: 若 X^a 是网络的一个吸引子, 则与 X^a 的海明距离 $dH(X^a, X^b)=1$ 的 X^b 一定不是吸引子。

证明: 不妨设 $x_1^a \neq x_1^b$, $x_j^a \neq x_j^b$, $j=2,3,\dots,n$ 。

$\because w_{11}=0$, 由吸引子定义, 有

$$x_1^a = f\left(\sum_{i=2}^n w_{1i} x_i^a - T_1\right) = f\left(\sum_{i=2}^n w_{1i} x_i^b - T_1\right)$$

由假设条件知, $x_1^a \neq x_1^b$, 故

$$x_1^b \neq f\left(\sum_{i=2}^n w_{1i} x_i^b - T_1\right)$$

$\therefore X^b$ 不是吸引子 (注: 公式中 w_{1i} 为 w_{1i})



反馈神经网络

能使网络稳定在同一吸引子的所有初态的集合，称为该吸引子的吸引域。


定义：若 $\underline{X^a}$ 是吸引子，对于异步方式，若存在一个调整次序，使网络可以从状态 \underline{X} 演变到 $\underline{X^a}$ ，则称 \underline{X} 弱吸引到 $\underline{X^a}$ ；若对于任意调整次序，网络都可以从状态 \underline{X} 演变到 $\underline{X^a}$ ，则称 \underline{X} 强吸引到 $\underline{X^a}$ 。

定义：若对某些 \underline{X} ，有 \underline{X} 弱吸引到吸引子 $\underline{X^a}$ ，则称这些 \underline{X} 的集合为 $\underline{X^a}$ 的弱吸引域；若对某些 \underline{X} ，有 \underline{X} 强吸引到吸引子 $\underline{X^a}$ ，则称这些 \underline{X} 的集合为 $\underline{X^a}$ 的强吸引域。



反馈神经网络

例：设有3节点DHNN网，用无向图表示如下，权值与阈值均已标在图中，试计算网络演变过程的状态。





反馈神经网络

解：设各节点状态取值为1 或0 ， 3 节点DHNN 网络应有 $2^3=8$ 种状态。不妨将 $X=(x_1, x_2, x_3)^T=(0,0,0)^T$ 作为网络初态，按 $1 \rightarrow 2 \rightarrow 3$ 的次序更新状态。

第1步：更新 x_1 ，

$$\begin{aligned} x_1 &= \text{sgn}[(-0.5) \times 0 + 0.2 \times 0 - (-0.1)] \\ &= \text{sgn}(0.1) = 1 \end{aligned}$$

其它节点状态不变，网络状态由 $(0,0,0)^T$ 变成 $(1,0,0)^T$ 。如果先更新 x_2 或 x_3 ，网络状态将仍为 $(0,0,0)^T$ ，因此初态保持不变的概率为 $2/3$ ，而变为 $(1,0,0)^T$ 的概率为 $1/3$ 。



反馈神经网络

第2步：此时网络状态为 $(1,0,0)^T$ ，更新 x_2 后，得

$$x_2 = \text{sgn}[(-0.5) \times 1 + 0.6 \times 0 - 0] = \text{sgn}(-0.5) = 0$$

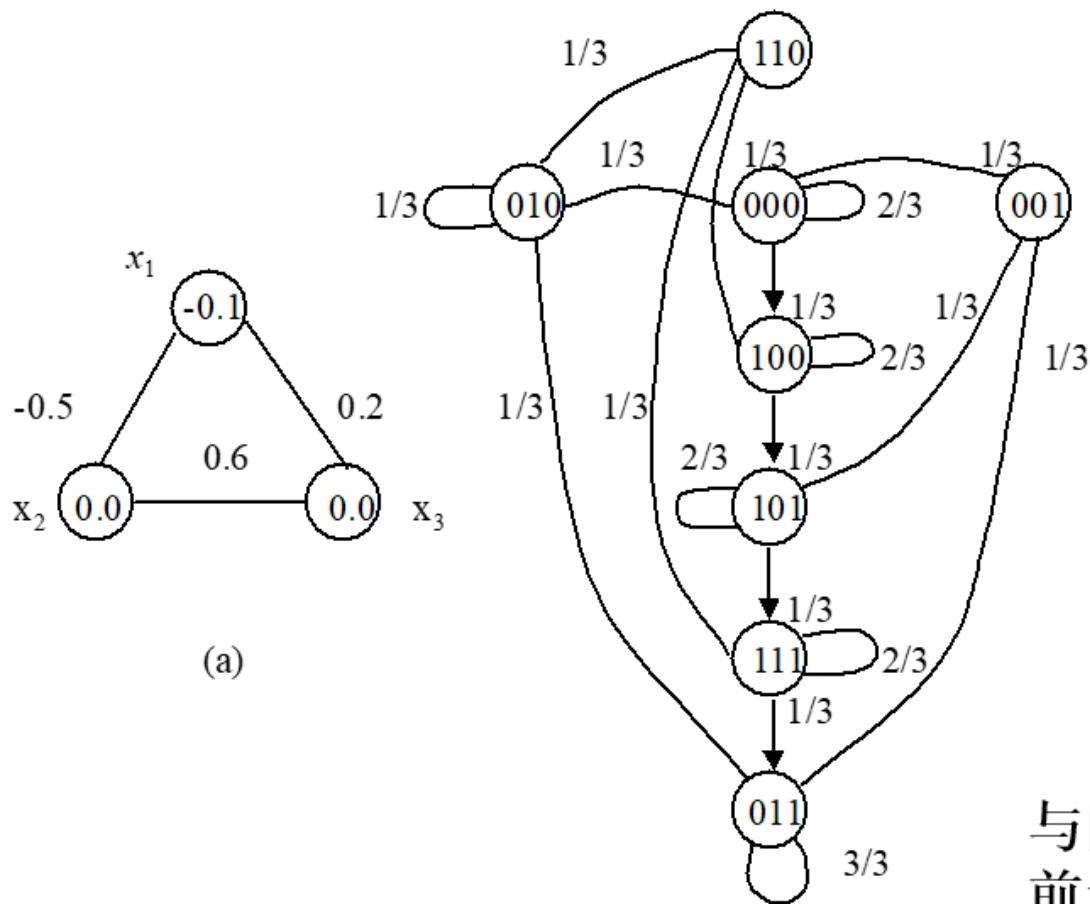
其它节点状态不变，网络状态仍为 $(1,0,0)^T$ 。如果本步先更新 x_1 或 x_3 ，网络相应状态将为 $(1,0,0)^T$ 和 $(1,0,1)^T$ ，因此本状态保持不变的概率为 $2/3$ ，而变为 $(1,0,1)^T$ 的概率为 $1/3$ 。

第3步：此时网络状态为 $(1,0,0)^T$ ，更新 x_3 得

$$x_3 = \text{sgn}[0.2 \times 1 + 0.6 \times 0 - 0] = \text{sgn}(0.2) = 1$$

同理可算出其它状态之间的演变历程和状态转移概率。

反馈神经网络



灌输式学习
死记硬背学习

此吸引子是由权值
与阈值决定的，是提
前设计出来的。

DHNN网络状态演变示意图

(b)



反馈神经网络

7、网络的权值设计

为了使所设计的权值满足要求，权值矩阵应符合以下要求：

- (1) 为保证异步方式工作时网络收敛， \mathbf{W} 应为对称阵；
- (2) 为保证同步方式工作时网络收敛， \mathbf{W} 应为非负定对称阵；
- (3) 保证给定样本是网络的吸引子，并且要有一定的吸引域。

- 联立方程法

以3节点DHNN网为例，设要求设计的吸引子为 $X^a = (0 \ 1 \ 0)^T$ 和 $X^b = (1 \ 1 \ 1)^T$ 权值和阈值在 $[-1,1]$ 区间取值， $w_{ij} = w_{ji}$ ，试求权值和阈值。



反馈神经网络

对于状态 $X^a = (0 \ 1 \ 0)^T$ ，各节点净输入应满足：

$$\text{net}_1 = w_{12} \times 1 + w_{13} \times 0 - T_1 = w_{12} - T_1 < 0$$

$$\text{net}_2 = w_{12} \times 0 + w_{23} \times 0 - T_2 = -T_2 > 0$$

$$\text{net}_3 = w_{13} \times 0 + w_{23} \times 1 - T_3 = w_{23} - T_3 < 0$$

对于状态 $X^b = (1 \ 1 \ 1)^T$ ，各节点净输入应满足：

$$\text{net}_1 = w_{12} \times 1 + w_{13} \times 1 - T_1 > 0$$

$$\text{net}_2 = w_{12} \times 1 + w_{23} \times 1 - T_2 > 0$$

$$\text{net}_3 = w_{13} \times 1 + w_{23} \times 1 - T_3 > 0$$



反馈神经网络

联立以上6项不等式，可求出6个未知量的允许取值范围。

如果 $w_{12} = 0.5$ $0.5 < T_1 \leq 1$ ，取 $T_1 = 0.7$

有 $0.2 < w_{13} \leq 1$ ，取 $w_{13} = 0.4$ ；

有 $-1 \leq T_2 < 0$ ，取 $T_2 = -0.2$ ；

有 $-0.7 < w_{23} \leq 1$ ，取 $w_{23} = 0.1$ ；

有 $-1 \leq T_3 < 0.5$ ，取 $T_3 = 0.4$ 。

可以验证，利用这组参数构成的DHNN网对于任何初态最终都将演变到一个吸引子。具体收敛到两个吸引子的哪个，取决于初始条件与异步次序。



反馈神经网络

- 外积和法

设给定 P 个模式样本 X^p ， $p=1,2,\dots,P$ ， $x \in \{-1,1\}^n$ ，并设样本两两正交，且 $n > P$ ，则权值矩阵为记忆样本的外积和

$$W = \sum_{p=1}^P X^p (X^p)^T$$

若取 $w_{jj}=0$ ，上式应写为

$$W = \sum_{p=1}^P [X^p (X^p)^T - I]$$

式中 I 为单位矩阵。上式写成分量元素形式，有

$$w_{ij} = \begin{cases} \sum_{p=1}^P x_i^p x_j^p & i \neq j \\ 0 & i = j \end{cases}$$



反馈神经网络

下面检验所给样本能否称为吸引子。

因为 P 个样本 \underline{X}^p , $p=1,2,\dots,P$, $x \in \{-1,1\}^n$ 是两两正交的, 有

$$(\underline{X}^p)^T \underline{X}^k = \begin{cases} 0 & p \neq k \\ n & p = k \end{cases}$$

$$\begin{aligned} W\underline{X}^k &= \sum_{p=1}^P [\underline{X}^p (\underline{X}^p)^T - I] \underline{X}^k \\ &= \sum_{p=1}^P [\underline{X}^p (\underline{X}^p)^T \underline{X}^k - \underline{X}^k] \\ &= \underline{X}^k (\underline{X}^k)^T \underline{X}^k - P \underline{X}^k \\ &= n \underline{X}^k - P \underline{X}^k = (n - P) \underline{X}^k \end{aligned}$$

因为 $n > P$, 所以有

$$f(W\underline{X}^p) = f[(n - P)\underline{X}^p] = \text{sgn}[(n - P)\underline{X}^p] = \underline{X}^p$$

可见给定样本 \underline{X}^p , $p=1,2,\dots,P$ 是吸引子。



反馈神经网络

8、网络信息存储容量

定理：若DHNN网络的规模为 n ，且权矩阵主对角线元素为0，则该网络的信息容量上界为 n 。

定理：若 P 个记忆模式 X^p , $p=1, 2, \dots, P$, $x \in \{-1, 1\}^n$ 两两正交, $n > P$, 且权值矩阵 W 按外积和得到, 则所有 P 个记忆模式都是DHNN网 (W, θ) 的吸引子。

$$W = \sum_{p=1}^P [X^p (X^p)^T - I]$$



反馈神经网络

定理：若 P 个记忆模式 X^p , $p=1, 2, \dots, P$, $x \in \{-1, 1\}^n$ 两两正交, $n \geq P$, 且权值矩阵 W 按下式得到, 则所有 P 个记忆模式都是DHNN网 (W, θ) 的吸引子。

$$W = \sum_{p=1}^P X^p (X^p)^T$$

表明自反馈增强了记忆功能。

由以上定理可知, 当用外积和设计DHNN网时, 如果记忆模式都满足两两正交的条件, 则规模为 n 维的网络最多可记忆 n 个模式。一般情况下, 模式样本不可能都满足两两正交的条件, 对于非正交模式, 网络的信息存储容量会大大降低 ($0.15n$, 经验公式)。



反馈神经网络

- 权值移动与交叉干扰

$$W = \sum_{P=1}^P \left[X^P (X^P)^T - I \right] \longrightarrow \begin{cases} W^0 = 0 \\ W^1 = X^1 (X^1)^T - I \\ W^2 = W^1 + X^2 (X^2)^T - I \\ \vdots \\ W^P = W^{P-1} + X^P (X^P)^T - I \end{cases}$$



反馈神经网络

当网络规模 n 一定时，要记忆的模式数越多，联想时出错的可能性越大；反之，要求的出错概率越低，网络的信息存储容量上限越小。研究表明存储模式数 P 超过 $0.15n$ 时，联想时就有可能出错。错误结果对应的是能量的某个局部极小点，或称为伪吸引子。

提高网络存储容量有两个基本途径：

- 改进网络的拓扑结构（ $n \uparrow$ ，加自反馈）
- 改进网络的权值设计方法（参看最新文献）